

ChemAI: Predict the Cure

Предсказание IC50, CC50, SI по молекулярным дескрипторам.

Public Kaggle score: 293.8085 RMSE

Сергей Петров, ДПО.

Задача и метрика







- **Соревнование:** <https://www.kaggle.com/competitions/chem-ai-predict-the-cure/overview>
- Необходимо предсказать три показателя для каждого химического соединения:
 - IC50 (mM) — концентрация, при которой вещество подавляет 50% активности вируса
 - CC50 (mM) — концентрация, при которой вещество токсично для 50% клеток
 - SI (Selectivity Index) — индекс селективности

Метрика — средний RMSE по IC50, CC50, SI;

Данные: 750 train, 250 test, числовые молекулярные признаки. Есть пропуски (заполняются медианой в пайплайне)

Анализ таргетов

- Исследовательский анализ данных показал, что целевые переменные имеют выраженную асимметрию и длинные правые хвосты.
- Это важно, потому что RMSE сильно штрафует большие ошибки на крупных значениях.
- IC50 и CC50 имеют выбросы, SI особенно нестабилен из-за редких очень больших значений, поэтому использовались $\log_{10}$ -преобразования таргетов



Проверенные гипотезы

Подход	Результат
Дополнительный feature engineering	Не улучшил CV
$\log_{1p}(\text{target})$	Сделал обучение устойчивее
Отдельные модели по таргетам	Лучше, чем единая логика для всех
Seed-ансамбль	Снизил дисперсию предсказаний

Feature engineering не был включён в финальную модель, потому что новые признаки оказались коррелированы с уже существующими дескрипторами и ухудшили модель

Сравнение моделей

На базовом этапе сравнивались:

- ExtraTreesRegressor
- RandomForestRegressor
- HistGradientBoostingRegressor

Лучший общий baseline: ExtraTrees: 542.9 (OOF mean-RMSE), результат на Kaggle порядка 313

Разные таргеты лучше предсказывались разными моделями, поэтому финальное решение стало таргет-специфичным.

model	IC50_RMSE	CC50_RMSE	SI_RMSE
ExtraTrees	357.8	491.7	779.2
RandomForest	355.7	516.9	779.6
HistGradientBoosting	366.0	510.4	778.3

Финальный пайплайн

Финальное решение:

- Разделение признаков и таргетов
- SimpleImputer для пропусков (заполнены медианой)
- VarianceThreshold для удаления константных признаков
- SelectKBest для части моделей
- Отдельная модель для каждого таргета: для IC50 использовался RandomForest, для CC50 — ExtraTrees, для SI — отдельный RandomForest.
- Усреднение по нескольким random seed
- Для IC50 и CC50 использовалась смесь (меньше переобучается, чем чистая raw-модель, но меньше занижает хвосты, чем чистая log-модель):
 - log-модель (дает стабильный прогноз, но часто занижает большие значения, т.к. сглаживает хвосты)
 - raw-модель (обучается на исходных значениях, лучше видит большие значения, потому что большая ошибка на большом таргете штрафуются)
- Для SI — отдельная модель без формулы CC50 / IC50.

Проверка результатов на Kaggle

Результат: 293.8085 RMSE

Лучший результат получен после:

- отдельного моделирования таргетов;
- log/raw-компонент для IC50 и CC50;
- отказа от feature engineering, ухудшающего прогноз;
- отдельной модели для SI;
- seed-ансамбля.

Leaderboard

[Raw Data](#)[Refresh](#)

YOUR RECENT SUBMISSION



submission.csv

Submitted by SP · Submitted 20 seconds ago

Score: 293.80850

↓ [Jump to your leaderboard position](#)